Introducción

Tiempo estimado: 40min

Bienvenido/a al curso Aprende bases de datos NoSQL con Redis. Su objetivo es introducir las bases de datos NoSQL, concretamente el modelo clave-valor, mediante Redis. Al finalizarlo, el estudiante conocerá este tipo de bases de datos, su terminología y, además, sabrá trabajar con Redis.

La lección comienza introduciendo el concepto de sistema de bases de datos y sus principales arquitecturas de desarrollo. A continuación, se introduce el mundo NoSQL, describiendo qué es NoSQL y los tres modelos más utilizados hoy en día: los almacenes clave-valor, los almacenes de documentos y los almacenes de grafos. Después se presenta las principales características de los sistemas de gestión de bases de datos NoSQL. Finalmente, se introduce Redis y se proporciona información sobre el curso.

Al finalizar la lección, el estudiante sabrá:

- Qué es un sistema de gestión de bases de datos.
- Cuáles son las dos arquitecturas principales de desarrollo de sistemas de bases de datos: la biblioteca integrable y el motor cliente/servidor.
- Qué es NoSQL.
- Cuáles son las principales características de los motores NoSQL.
- Qué es una base de datos clave-valor y para qué se suele utilizar.
- Qué es una base de datos de documentos y para qué se suele utilizar.
- Qué es una base de datos de grafos y para qué se suele utilizar.
- Qué es una base de datos multimodelo.

Introducción

Un sistema de gestión de bases de datos (*database management system*) o SGBD (*DBMS*) es un software que gestiona bases de datos. La idea que se esconde tras este tipo de productos es delegar en ellos la gestión, administración y el control de acceso a los datos, mediante un producto especializado en estas funciones. Esto mejora el rendimiento final de las aplicaciones y la integridad de los datos almacenados así como facilita el desarrollo de aplicaciones e incrementa la productividad de los equipos de desarrollo.

Las principales funciones de un SGBD son:

- Administrar adecuadamente el almacenamiento de los datos en los dispositivos de almacenamiento.
- Administrar adecuadamente la memoria utilizada por el SGBD para que no robe toda la memoria del sistema e impida la ejecución de otros programas en la misma máquina.
- Controlar o regular el acceso a los datos según el usuario que se encuentre detrás. No todos los usuarios tiene por qué poder acceder a todos los datos.

Atendiendo a su arquitectura, podemos distinguir básicamente dos tipos de motores de bases de datos, los que se implementan mediante una arquitectura cliente/servidor y las bibliotecas integrables.

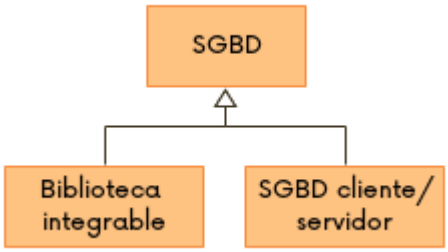

LevelDB, SQLite y PouchDB son ejemplos de bibliotecas integrables (*embeddable libraries*), componentes de software que se pueden integrar dentro de las propias aplicaciones. El motor lo implementa un equipo especializado de ingenieros que proporcionan una biblioteca reutilizable que se integra muy fácilmente en las aplicaciones. Se ejecutan dentro del proceso de la propia aplicación. No son recomendables para proyectos medianos y grandes que requieren control de acceso desde varias aplicaciones y/o por varios usuarios. Son muy útiles.

En cambio, un sistema cliente/servidor (*client/server system*) es aquel que distingue entre aplicación cliente (*client*), aquella que desea acceder a los datos, y aplicación servidora (*server*), aquella que se encarga de administrar y controlar el acceso a los datos. Cada una de ellas se ejecuta en un proceso aparte e incluso, lo más frecuente, en máquinas distintas. La mayoría de SGBDs son de este segundo tipo como, por ejemplo, ArangoDB, Cassandra, CouchDB, MariaDB, MongoDB, PostgreSQL, Redis, RethinkDB y SQL Server.

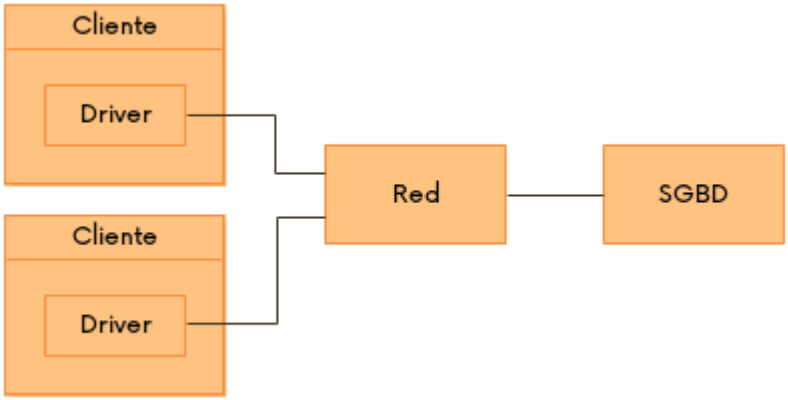

En un modelo cliente/servidor, los datos pueden ser accedidos por distintas aplicaciones clientes, lo que no ocurre en el modelo de biblioteca integrable donde sólo la aplicación que integra el motor puede acceder a los datos.

Para acceder a los SGBDs, las aplicaciones utilizan drivers, componentes de software especializados para el acceso a servidores de base de datos. En el caso de una biblioteca integrable, el *driver* suele llevar consigo la propia biblioteca. En el caso de SGBDs cliente/servidor, los *drivers* accederán a los servidores de bases de datos mediante la red. A la hora de elegir un SGBD u otro, una de las cosas que hay que mirar es si dispone de *driver* para nuestra plataforma de desarrollo y, a ser posible, oficial del fabricante para asegurarnos que se actualiza a un ritmo razonable con respecto a la evolución del producto.

Por otra parte, principalmente, existe dos tipos de sistemas de bases de datos, los relacionales o SQL y los NoSQL. El objeto del presente curso es el sistema de gestión de bases de datos Redis con el que aprender sobre bases de datos NoSQL.

NoSQL es un tipo o familia de sistemas de gestión de bases de datos que *no* sigue los principios de los sistemas relacionales o SQL. El término NoSQL tiene básicamente dos acepciones: no SQL o *Not Only SQL* (no sólo SQL). La primera hace hincapié en que *no* usa los principios relacionales, mientras que la segunda indica que SQL *no* es la única tecnología de bases de datos.

Los sistemas de gestión de bases de datos NoSQL no tienen como objeto, en ningún caso, sustituir a los sistemas de gestión SQL. Pero sí proporcionar una herramienta adicional o alternativa que permita atender mejor aquellas situaciones para las que las bases de datos SQL no son óptimas o presentan un mal rendimiento. Diferentes tipos de aplicación requiere diferentes tipos de bases de datos. Es

inevitable pues que los especialistas de bases de datos conozcan y usen distintos SGBDs, tanto SQL como, por ejemplo, MariaDB, PostgreSQL o SQL Server, así como NoSQL como ArangoDB, Cassandra, CouchDB, MongoDB, Redis, RethinkDB o ValenciaDB.

Bases de datos NoSQL

Aproximadamente, en 2005 comenzó una nueva revolución de bases de datos, orientada a NoSQL, con un objetivo principal: llenar ese vacío donde SQL proporciona un mal rendimiento debido a su forma de trabajar. Son muchos los productos NoSQL que han aparecido desde entonces. Los principales son ArangoDB, Cassandra, CouchDB, InfluxDB, MongoDB, Redis y RethinkDB. Cada uno de ellos tiene como objeto llenar uno o más huecos de SQL.

Una base de datos (*database*) es una colección estructurada de datos y/u objetos, organizada atendiendo a la especificación de un determinado modelo de base de datos. Ya sabemos que existe diversos tipos de bases de datos como, por ejemplo, las relacionales, las orientadas a documentos, las de clave-valor o las de grafos.

Como vemos, existe varios modelos de datos, donde un modelo de datos (*data model*) lo que hace es describir una manera de trabajar. Una forma de organizar, almacenar y acceder a los datos. En estos momentos, el más conocido y usado en todo el mundo es el modelo relacional implementado por los motores SQL. Otros menos conocidos pero que van abriéndose paso rápidamente son algunos NoSQL como, por ejemplo, el de documentos, el de clave-valor y el de grafos.

Algunos sistemas de gestión de bases de datos soportan sólo un único modelo, mientras que otros soportan varios. Estos últimos se conocen formalmente como bases de datos multimodelo (*multimodel databases*). La idea que se esconde detrás de un sistema multimodelo es muy sencilla: combinar varios modelos de datos en un único producto, usando el mismo lenguaje de consulta para todos ellos.

Los sistemas NoSQL se utilizan ampliamente y cada día más. Organizaciones de cualquier tamaño e índole como, por ejemplo, Adobe, Amazon, AOL, Barclays, Canonical, Cisco, Disney, EA, eBay, Ericsson, Facebook, Forbes, Google, HP, IBM, LinkedIn, McDonald's, Microsoft, MTV, NASA, RedHat, Telefónica, The Guardian, The New York Times y Twitter están utilizando sistemas NoSQL. Especialmente las *startups* son las que las utilizan con fervor para desarrollar sus productos más rápidamente.

Almacenes clave-valor

Un almacén clave-valor (*key-value store*) es un tipo de sistema NoSQL que almacena datos en forma de tabla o *array* asociativo. Los datos se agrupan en pares, donde un par (*pair*) no es más que un objeto o registro de datos formado por dos elementos: una clave y un valor. La clave (*key*) representa el identificador a utilizar para acceder al objeto o registro. Y el valor (*value*) contiene los datos.

La clave suele ser de tipo texto, pero el valor puede ser de cualquier otro tipo como, por ejemplo, un número, un objeto, un *array* u otro texto.

Este tipo de sistemas se diseña básicamente con dos objetivos: sencillez y rendimiento. Como son el tipo de base de datos más simple, son fáciles de implementar, no presentan grandes complejidades. Por otra parte, se diseñan buscando extraer el máximo rendimiento del sistema de bases de datos, dentro de su margen de maniobra.

Pero al igual que cualquier otro tipo de sistema de bases de datos, los almacenes clave-valor no se pueden utilizar en cualquier proyecto. Sus principales usos son:

- El cacheo de datos.
- El almacenamiento de información de sesión.
- El almacenamiento de datos de *reporting*.
- El almacenamiento de datos temporales.

- El almacenamiento de catálogos de productos.
- El almacenamiento de registros de mensajes o eventos.

Entre otros productos de este tipo encontramos Amazon SimpleDB, ArangoDB, Redis, Riak KV y ValenciaDB.

Algunas compañías suelen usar almacenes clave-valor como caché poniéndola delante de otros motores. En estos casos, el almacén principal de datos es el otro motor, independientemente de su tipo. Pero si la aplicación requiere mucho procesamiento de datos, lecturas y/o escrituras intensivas, se suele utilizar almacenes clave-valor. Estos motores suelen tener mejor rendimiento que otros en L/E. Cuando se ha terminado el procesamiento intensivo, entonces se cogen los datos y se vuelcan al almacén principal. Por ejemplo, en un portal web con mucho tráfico, la información de sesión, la publicidad, las páginas webs consultadas, etc. se puede almacenar en un almacén clave-valor. Una vez se cierra la sesión, se coge la información recopilada y se vuelca al sistema principal de almacenamiento sea SQL u otro NoSQL.

Almacén de documentos

Otro de los tipos de bases de datos NoSQL más utilizado es el almacén de documentos (*document store*), que tiene como objeto almacenar objetos de datos, tanto estructurados como desestructurados, conocidos formalmente como documentos (*documents*). A diferencia de los almacenes clave-valor donde los datos se acceden generalmente mediante la clave, en los almacenes de documentos, las cosas no son iguales, y se puede acceder a un documento a partir de cualquiera de sus campos.

Una de las principales ventajas de este tipo de almacenes es que pueden contener, en un único documento, toda su información. Lo que facilita su acceso. A diferencia de las bases de datos relacionales donde para obtener toda la información hay que utilizar JOINs, operaciones de reunión de datos procedentes de distintas tablas.

El desarrollo de aplicaciones con bases de datos orientadas a documentos es más fácil y rápido que con una base de datos relacional. Pero obviamente, sacrifica algunos aspectos para conseguirlo como, por ejemplo, la integridad de los datos.

Sus principales usos son:

- El cacheo de datos.
- El almacenamiento de información de sesión.
- La consolidación de datos mediante puntos de vista particulares.
- El análisis de datos a partir de datos consolidados.
- El almacenamiento de datos de *reporting*.
- El almacenamiento de catálogos de productos.
- El almacenamiento de registros de mensajes o eventos.
- El almacenamiento de datos personalizables por los usuarios.
- La gestión y la publicación de contenido.
- El almacenamiento de datos de sitios webs.

Entre los principales productos de este tipo encontramos ArangoDB, CouchDB, DocumentDB, MongoDB y RethinkDB.

Esquema de documento

Un esquema (*schema*) define el conjunto de campos que debe presentar un documento. Los documentos se almacenan dentro de colecciones, las cuales representan contenedores donde almacenar documentos.

Conceptualmente, en bases de datos, independientemente de si son SQL o NoSQL, los esquemas se clasifican principalmente en estrictos y flexibles.

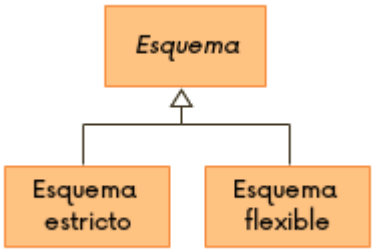

Un esquema estricto (*strict schema*), también conocido como esquema estático (*static schema*), es aquel que define exactamente qué campos debe presentar cada documento de la colección, así como los tipos de los valores. Todo documento debe cumplir necesariamente el esquema de su colección. No se puede añadir un documento a una colección si no cumple con el esquema definido en la colección en la que se almacena. Es el tipo de esquema que predomina en motores SQL y algunos NoSQL como, por ejemplo, Cassandra, PostgreSQL, SQL Server y SQLite.

En cambio, un esquema flexible (*flexible schema*), también conocido como esquema dinámico (*dynamic schema*) o sin esquema (*schemaless*), es más flexible y no define ningún tipo de restricción en los campos que debe presentar el documento. Esto quiere decir que en una colección se podrá almacenar documentos con esquemas distintos y tipos de datos distintos para campos homónimos. Aunque generalmente, por convenio, se suele seguir un esquema muy similar. Se utiliza en sistemas de gestión de bases de datos como, por ejemplo, ArangoDB, CouchDB, MongoDB y RethinkDB.

En un esquema estricto, todos los documentos presentan los mismos campos y sus valores, a su vez, deben tener los mismos tipos. En cambio, en un esquema flexible, esto no es necesario y cada documento puede tener su propio esquema, o sea, puede disponer de cualquier número de campos con valores de cualquier tipo. Cuando se utiliza un esquema dinámico, es obligación de las aplicaciones asegurar que los datos insertados cumplen los esquemas *pactados* si el motor no proporciona algún mecanismo nativo para hacerlo.

Los esquemas flexibles ayudan enormemente al desarrollo rápido de aplicaciones, sobre todo en el desarrollo de aplicaciones webs, pues aumenta la productividad. Una de las principales razones por las que se utiliza bases de datos de documentos y clave-valor. En SQL, si añadimos una nueva columna a una tabla, hay que garantizar que todas las filas ya existentes cumplen con las restricciones de la nueva columna. Esto es sencillo de ver. ¿Qué ocurre si añadimos una nueva columna a la tabla y ésta es obligatoria, es decir, toda fila debe proporcionar un valor para la columna? Si la tabla ya tiene filas, éstas no tendrán datos para esa nueva columna, por lo que habrá que hacer un trabajo extra: primero, declarar la columna como opcional; después, ejecutar una consulta que añada el valor para esa nueva columna en todas las filas existentes; y finalmente, definir la columna como obligatoria. Como puede observar, es sencillo pero algo tedioso. En los esquemas flexibles, esto no es necesario.

Algunos fabricantes de almacenes NoSQL consideran el uso de los esquemas flexibles como una ventaja. Esto lo es, pero a su vez no lo es. Por un lado, lo es, porque se desarrolla más rápidamente al no tener que definir los esquemas de las colecciones. Pero no lo es porque el esquema flexible hace que los datos ocupen más espacio en el dispositivo de almacenamiento y en memoria.

Debe quedar claro que como las colecciones no tienen asociado ningún esquema, los documentos que pueden almacenar pueden presentar cualquier esquema. Esto hace que la instancia deba almacenar, para cada documento, tanto su esquema como los valores de los campos. Esto hará que si una colección contiene un millón de documentos, todos ellos con el mismo esquema, digamos por ejemplo de cinco campos, como la colección no fija ningún esquema, cada documento almacenará el nombre de los cinco campos con sus respectivos valores y tipos, ¡para el millón de documentos! En sistemas con esquemas estáticos, habría un millón de documentos, se fijaría el orden en que cada campo se debe almacenar, de tal manera que el primer valor pertenecería siempre al primer campo; el segundo al segundo; y así sucesivamente. Y por otra parte, cada campo contendrá siempre un valor de un tipo determinado. Pero no se almacenaría un millón de veces el nombre de cada campo. Así pues, cuanto mayor sea el nombre, más espacio será requerido en memoria y en disco. A su vez, cuanto más espacio ocupa un documento en disco, más operaciones de E/S será necesario realizar; siendo las operaciones de E/S el principal cuello de botella de las bases de datos.

En resumen, la utilización de sistemas de gestión de bases de datos NoSQL tiene ventajas y desventajas. Cuando se utilizan, se entra al *juego*, se acepta las cosas como son, con lo bueno y lo malo. Al igual que

cuando se utiliza un sistema relacional.

Almacenes de grafos

Un almacén de grafos (*graph store*) permite el almacenamiento de datos relacionados en forma de grafos. Se basan en la teoría matemática de grafos, la cual tiene como objeto representar datos mediante puntos y líneas que se utilizan para resolver problemas de análisis.

Las principales áreas en las que se usa este tipo de bases de datos son:

- La medicina.
- El transporte y la logística.
- Las redes sociales.
- La seguridad como, por ejemplo, detección de fraudes.
- La gestión de tráfico.

Básicamente, lo que se busca con este tipo de bases de datos es facilitar el análisis de los datos representados mediante grafos para extraer hechos o datos que nos ayuden a tomar decisiones.

Entre los principales productos que soportan este tipo de bases de datos encontramos ArangoDB, DataStax, Neo4j y OrientDB.

Estructura de los almacenes de datos

Las implementaciones llevadas a cabo por los distintos fabricantes pueden diferir en algo. Atendiendo a si permite organizar a los usuarios sus pares clave-valor o sus documentos en contenedores o colecciones dentro de la base de datos, se distingue entre almacenes estructurados y desestructurados.

Un almacén estructurado (*structured datastore*) es aquel que permite a los usuarios organizar los pares en contenedores o colecciones específicas dentro de la bases de datos. Cada una generalmente con el objeto de almacenar los pares clave-valor relacionados con un determinado tipo de entidad.

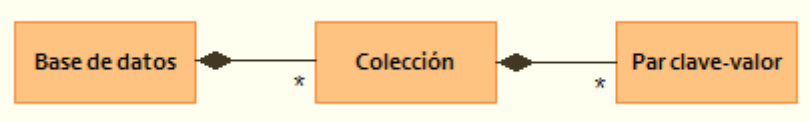

En cambio, un almacén desestructurado (*non-structured datastore*) es aquel en el que cada base de datos actúa como un contenedor único de pares clave-valor, no permitiendo organizarlos en colecciones. Cada base de datos es como una única colección donde todos los pares se encuentran almacenados.

Aunque pueda parecer que los almacenes estructurados son mejores, no es cierto, ni lo contrario tampoco. Cada tipo tiene sus ventajas y desventajas. CouchDB, LevelDB y Redis son ejemplos claros de almacenes desestructurados, todos los pares se encuentran almacenados juntos en la base de datos, siendo necesario identificar la entidad a la que pertenecen de alguna manera, generalmente, mediante el identificador de la clave.

Para comenzar, en un modelo estructurado, por definición y formas, todo está bien organizado. Cada par clave-valor pertenece a una colección. Por lo que si deseamos acceder a los pares relacionados con una determinada entidad, es tan sencillo como consultar su colección.

En un modelo desestructurado, como todos los pares clave-valor se encuentran, digamos, dentro de una única colección, la base de datos, debemos definir algún convenio para determinar a qué colección *virtual* pertenece cada uno de ellos. Esto que parece difícil no lo es en absoluto. Groso modo, se utiliza el propio identificador del par para indicar la colección virtual a la que pertenece.

Así, cuando deseamos acceder a los pares de una determinada entidad, habrá que realizar una consulta que indique el selector de entidad. A bote pronto, no parece que sea difícil ni traumático para los desarrolladores.

Bases de datos en memoria

Un sistema de bases de datos en memoria (*in-memory database system*) utiliza principalmente la memoria RAM para almacenar sus datos. A diferencia de un sistema de bases de datos en disco (*on-disk database system*) que utiliza como principal fuente de almacenamiento el disco. Redis y VoltDB son ejemplos de sistemas de bases de datos en memoria. Cassandra, CouchDB, MongoDB y PostgreSQL en disco. Algunos motores como ArangoDB, DataStax, SQL Server, SQLite y ValenciaDB han comenzado a desarrollar sistemas híbridos, con capacidad para que determinadas tablas se encuentren en memoria y otras en disco.

El uso de la memoria como dispositivo de almacenamiento de los datos es mejor porque el motor tiene acceso mucho más rápido a los datos al no tener que pasar por el sistema de E/S de disco. Elimina el tiempo de búsqueda inherente cuando se solicita un dato almacenado en disco que no se encuentra en la memoria RAM.

Hay que decir que las bases de datos en memoria utilizan los discos, pero no como lo hacen las bases de datos en disco. Lo utilizan para hacer instantáneas de los datos en memoria, como mecanismo de copia de seguridad. Y por otra parte, como dispositivo donde depositar el registro de transacciones. La idea es que cuando arranca la instancia, lee todos sus datos de disco y los vuelca en la memoria RAM. El disco deja de usarlo, mejorándose considerablemente el rendimiento. Sólo lo usará cuando tenga que volcar el contenido a disco, por ejemplo, para hacer una copia de seguridad por si se produce un fallo.

O para almacenar las operaciones de escritura en el registro de transacciones.

Por su parte, una base de datos en disco también usa la memoria. Todo dato, para poder ser procesado por el motor, es necesario que se encuentre en la memoria. Pero, digamos, no vuelca el contenido completo a memoria RAM. Sólo el accedido con más frecuencia. Por lo tanto, su dependencia del disco es inherente al motor y, por eso, son más lentos. Cuando tenga que acceder a un dato que no se encuentra en memoria RAM, tendrá que solicitárselo al disco y esperar a que se lo proporcione para poder continuar con la operación.

Características de las bases de datos NoSQL

Por lo general, los sistemas de gestión de bases de datos NoSQL presentan las siguientes características:

- Modelo de transacciones ACID, AID o BASE.
- Alta disponibilidad.
- Alta escalabilidad.
- Facilidad de uso.
- Modelos de datos desnormalizados.
- Precio.

Modelo de transacciones ACID, AID o BASE

Algunos sistemas NoSQL suelen usar el modelo de transacciones ACID, soportado íntegramente por los sistemas SQL. Y otros sólo AID o BASE. ACID es el acrónimo de *Atomic* (atómico), *Consistent* (consistente), *Isolated* (aislado) y *Durable*.

Atomicidad

Con la atomicidad (*atomicity*) lo que se busca es que los cambios realizados por toda transacción se confirmen. En caso de que un sólo cambio no se confirme, entonces todos los cambios realizados por la transacción se desharán dejando el sistema como estaba antes del inicio de la propia transacción. En el caso de SQL, las transacciones además suelen estar formadas por un conjunto de una, dos o más operaciones DML. En algunos sistemas de gestión de bases de datos NoSQL, las transacciones no suelen ser multioperación, es más, si una operación modifica varios registros, algunas bases de datos NoSQL suelen ser transaccional sólo a nivel de un único registro, lo que significa que garantizan que todo el registro se actualiza y si no se consigue, no realiza la operación; pero si la operación actualiza varios registros, si en alguno de ellos falla, no deshacen las modificaciones previas, sólo garantizan que la que ha fallado no se realizará.

Como acabamos de mencionar, la transaccionalidad a nivel de registro es casi un estándar de facto en los sistemas NoSQL, aunque por suerte cada día son más las que soportan el modelo ACID. Debido a que no tienen que preocuparse por un conjunto de operaciones ni por un conjunto de registros, los sistemas de gestión de bases de datos NoSQL presentan mejor rendimiento que las SQL porque se quitan un peso de encima. Obviamente, si la aplicación usuaria requiere transacciones multioperación o multiregistro, es muy probable que se dese utilizar una base de datos que soporte ACID, porque si no se hace así, recaerá en la propia aplicación garantizar la atomicidad a nivel de operación completa.

Por lo general, las bases de datos NoSQL no suelen ser adecuadas para sistemas críticos u OLTP.

Consistencia

Cuando se habla de consistencia (*consistency*), de lo que se habla es de que una transacción no puede dejar una base de datos en un estado inconsistente. En las bases de datos SQL, la consistencia se consigue mediante la utilización de restricciones de integridad, principalmente de integridad referencial o de dominio. Muchos sistemas NoSQL no implementan la integridad, haciendo a las aplicaciones responsables de mantener esta integridad de datos. Así, por ejemplo, si en SQL tenemos dos tablas madre-hija, si se define una restricción de integridad referencial en la que cuando se elimine una fila madre, automáticamente sus hijas se supriman también, esto hará que nunca haya una hija referenciando a una madre inexistente, manteniéndose así una integridad referencial y una consistencia

de datos. Recordemos que para relacionar las madres con sus hijas se utilizan las reuniones (JOINs).

En NoSQL, generalmente no es así, no se puede definir la integridad referencial en la base de datos. Así pues, si un registro referencia a otro, si la aplicación no se encarga de mantener la integridad referencial, habrá inconsistencia en la base de datos. Esto ayuda a los sistemas de gestión de bases de datos NoSQL a tener que preocuparse por menos cosas cuando realizan las operaciones de modificación. Esta descarga de responsabilidades hace que estos sistemas sean más rápidos y presenten mejores rendimientos, pero a cambio obligan a las aplicaciones a preocuparse por estas cosas.

Algunos fabricantes de sistemas de gestión de bases de datos hablan de consistencia relajada, pero generalmente no hay consistencia, ni siquiera relajada. Parece más un término de marketing que una realidad.

Aislamiento

Con el aislamiento (*isolation*), se está hablando de que los cambios realizados por una transacción no pueden interferir con los realizados por otra o, en otras palabras, un cambio realizado por una transacción no puede ser visto por otra hasta que la primera confirme que ha acabado y haya acabado con éxito. Tal como hemos comentado con la propiedad de atomicidad, las transacciones de las bases de datos NoSQL son generalmente a nivel de registro, asegurando que cualquier cambio sobre un registro no sea visible hasta que el cambio en el registro haya finalizado.

Durabilidad

Finalmente, la propiedad de durabilidad (*durability*) hace referencia a que cuando una transacción ha finalizado con éxito, sus datos son permanentes aún en caso de que se produzca un fallo en el sistema de gestión de bases de datos. Esto se consigue mediante el uso de registro de transacciones. Algunos sistemas NoSQL lo implementan pero con una variante que puede llevar a pérdida de datos, algo que también es posible en algunos sistemas SQL.

Alto rendimiento

Los sistemas NoSQL suelen presentar mejores rendimientos que los sistemas SQL. Como se ha presentado en el anterior apartado, los sistemas NoSQL se descargan de ciertas responsabilidades que tienen las SQL, por lo tanto, si no tienen que preocuparse de esas cosas, no tendrán que hacer ciertas comprobaciones internas y, por ende, tendrán mejores tiempos de respuesta.

Además, los sistemas NoSQL se diseñan teniendo muy claro que tienen que mejorar enormemente la E/S a disco, uno de los principales cuellos de botella que tiene cualquier sistema de gestión de bases de datos, independientemente de su tipo.

Generalmente, las bases de datos NoSQL permiten almacenar toda la información de registros relacionados juntos. Esto hará que cuando se tenga que extraer toda la información, se pueda hacer mediante una única operación de lectura, algo muy importante y que generalmente en los sistemas SQL requiere varias operaciones.

Por ejemplo, supongamos una orden de pedido. En una base de datos SQL, tendremos, por un lado, la tabla madre Pedido que contiene los datos generales del pedido como, por ejemplo, la fecha, el cliente, la dirección de entrega, etc. Por otro lado, una tabla aparte contendrá las líneas del pedido, cada una de las cuales contendrá la información de un artículo: su número de artículo, el precio del artículo y las unidades solicitadas. Esto significa que cuando queremos obtener la información completa del pedido, hay que juntar ambas tablas mediante una operación de reunión (JOIN). Además, las filas de un mismo pedido no tienen porque estar adyacentes, pueden estar repartidas por todo el disco; esto reduce todavía más el rendimiento de la base de datos. En cambio, por lo general, los sistemas NoSQL permiten almacenar toda esa información junta, lo que hará mucho más rápido su acceso que un sistema SQL, al no tener que realizar reuniones (JOINs) para obtenerla.

Los sistemas de gestión de bases de datos NoSQL suelen encontrarse optimizados para operaciones de lectura e inserción, o sea, abundan las lecturas de datos y las inserciones, no así las actualizaciones o supresiones. Esto no quiere decir que no sean óptimas para la actualización o supresión de registros de la base de datos, pero sí serán menos óptimas que esas mismas operaciones en una base de datos relacional. A cambio, si la base de datos presenta principalmente lecturas e inserciones, como ocurre en los *data warehouses* y en muchas aplicaciones webs, son mucho más óptimas que las relacionales.

Alta disponibilidad

La alta disponibilidad (*high availability*) hace referencia a que las bases de datos tienen que estar trabajando todo el tiempo posible, llegando incluso a no poder dejar de dar servicio bajo ningún concepto. En muchos casos, la parada de una base de datos durante horario de oficina puede conllevar la pérdida de miles e incluso cientos de miles de euros por cada hora de inactividad.

Los sistemas NoSQL suelen presentar mejor disponibilidad que las SQL, aunque eso no significa que las SQL no presenten esta propiedad. Así, por ejemplo, sistemas de gestión de bases de datos como Cassandra son sistemas distribuidos NoSQL que no presentan ningún punto de fallo. Si un nodo cae, cualquiera de los demás puede atender su carga sin pérdida de servicio, aunque claro está sí habrá peor rendimiento porque ahora hay un miembro menos para atender la carga de los usuarios. Otros sistemas como MongoDB y Redis sí presentan punto de fallo, aunque ayudan a levantar el entorno en caso de fallo. Pero hoy en día, casi todos los sistemas SQL que se precien como, por ejemplo, PostgreSQL y SQL Server proporcionan también una muy buena alta disponibilidad.

Alta escalabilidad

Cuando se habla de alta escalabilidad (*high scalability*), se habla de lo fácil que es ampliar un entorno, añadiendo principalmente más recursos. Generalmente, los motores NoSQL permiten escalabilidad de manera muy sencilla. Se puede repartir muy fácilmente los datos entre varias instancias. Además de ser muy fácil la añadidura o la supresión de una instancia asociada a un clúster. Pero también, es fácil hacerlo en sistemas SQL como PostgreSQL y SQL Server.

Facilidad de uso

Los sistemas NoSQL son muy fáciles de usar y administrar. Se diseñan teniéndolo en mente. Generalmente, son más fáciles de usar y administrar que los sistemas SQL, pero huelga decir que porque son, digamos sutilmente, mucho más pequeños.

Modelos de datos desnormalizados

Por lo general, cuando se usa sistemas NoSQL, se utiliza modelos de datos desnormalizados, a diferencia de los sistemas SQL donde se utiliza el modelo normalizado. Esto significa que en muchas ocasiones una base de datos NoSQL tiene datos duplicados para, así, mejorar su acceso.

Precio

El precio de instalación y uso de un sistema de gestión de bases de datos NoSQL es generalmente bastante más barato que uno SQL. En el caso de SQL, existe sistemas muy buenos y gratuitos como, por ejemplo, PostgreSQL. En el mundo NoSQL, también encontramos versiones gratuitas de ArangoDB, Cassandra, MongoDB y Redis. Otros fabricantes como Oracle y Microsoft disponen de sus propios sistemas de gestión de bases de datos, con precios bastante elevados, principalmente Oracle.

De cara a grandes empresas cuyas paradas debido a fallos puede conllevar unos costes elevados, existe versiones de pago con soporte del fabricante. Por ejemplo, DataStax proporciona una versión de pago y más potente de Cassandra; MongoDB Inc. hace lo mismo para MongoDB; ArangoDB GmbH para ArangoDB; Redis Labs para Redis; al igual que EnterpriseDB o VMware hacen con PostgreSQL.

Redis

Redis, el objeto del curso, es un sistema de gestión de base de datos NoSQL clave-valor. Es considerado uno de los sistemas de bases de datos de mayor crecimiento en los últimos años. Creado y desarrollado por el italiano Salvatore Sanfilippo, el proyecto ha sido patrocinado por compañías como VMware y Pivotal. Actualmente, el patrocinio corre de la mano de Redis Labs. Está escrito en C, es de código abierto y completamente gratuito.

Se puede ejecutar en Linux, Mac OS X y Windows, siendo Linux el entorno más utilizado en entornos de producción. Además, se puede ejecutar bajo PaaS o DBaaS en AWS, Bluemix, Google Cloud Platform, Microsoft Azure, OpenShift, Redis Cloud y SoftLayer, entre otros proveedores. Se dispone de *drivers* para plataformas Java, .Net, Node.js, PHP y Python, entre otras. Todo ello facilita su utilización y adopción.

Son muchas las organizaciones que utilizan este motor de bases de datos como, por ejemplo, Airbnd, Alcatel-Lucent, Alibaba, Amazon, American Express, AT&T, BBC, BitBucket, BlaBlaCar, Dell, Disqus, eBay, Electronic Arts, Flickr, GitHub, Groupon, IBM, Instagram, Microsoft, NASA, Pinterest, Pivotal, Rackspace, Sainsbury's, Sky, Telefónica, The Guardian, The New York Times, The Washington Post, Tumblr, Twitter, VMware, Yahoo! y Zalando, entre otras muchas.

Su página oficial es redis.io.

Principales características

Sus principales características son:

- Es un sistema de bases de datos clave-valor en memoria con soporte de persistencia.
- Utiliza esquemas flexibles.
- Lleva integrado un sistema de mensajería muy fácil de usar. Ideal para aplicaciones webs de tiempo real.
- Es ligera, de pequeño tamaño, y muy pero que muy rápida.
- Tiene muy buen rendimiento tanto en las lecturas como en las escrituras.
- Proporciona alta disponibilidad y escalabilidad mediante replicación y partición.
- Permite la creación de pares clave-valor volátiles, esto es, que se suprimirán automáticamente cuando se alcance un período de retención establecido de antemano.
- Se puede realizar *scripts* de servidor complejos mediante Lua.
- Se puede extender su lenguaje de consulta mediante módulos.
- Los valores pueden ser de distinto tipo, principalmente, cadenas de texto, números, listas, conjuntos y objetos. Otros tipos se pueden usar mediante el uso de módulos con, por ejemplo, valores de tipo JSON.
- Soporta búsqueda de texto (*full-text search*) o *machine learning* mediante módulos específicos.

Información del curso

Este curso está dedicado al sistema de gestión de bases de datos Redis.

Tiene como objetivo introducir al estudiante en el mundo de las bases de datos NoSQL, mediante una descripción detallada de este motor de bases de datos por su soporte del modelo clave-valor.

Al finalizarlo, el estudiante sabrá:

- Qué es NoSQL.
- Qué es un modelo de datos.
- Qué es un sistema de gestión de bases de datos.
- Qué es un almacén clave-valor, para qué se usa y cómo se implementa en Redis.
- Cómo se organizan los datos en bases de datos Redis.
- Cómo realizar consultas de extracción, inserción, actualización y supresión.
- Cómo ejecutar transacciones en Redis.
- Cómo usar el *shell* redis-cli.
- Cómo escribir *scripts* con el lenguaje de programación Lua.
- Cómo cargar módulos de terceros.

Conocimientos previos

El estudiante no debe tener conocimientos previos.

Plan del curso

El curso tiene una duración aproximada de 8 horas. Se divide en 17 lecciones y 2 apéndices con los que extender los conocimientos adquiridos de Lua.

A continuación, se enumera las distintas lecciones y el tiempo estimado para su estudio:

Lección	Teoría	Descripción
1 Introducción	40min	Esta lección.
2 Instancias de bases de datos	20min	Cómo instalar, compilar, arrancar, configurar y parar servidores de datos Redis.
3 Bases de datos	25min	En qué consiste una base de datos Redis y qué es un par clave-valor.
4 Cadenas	15min	Descripción del tipo de datos cadena y los comandos a utilizar con este tipo.
5 Módulos	5min	Qué es un módulo, cómo cargarlo y un ejemplo de compilación de módulo.
6 Listas	25min	Descripción del tipo de datos lista y los comandos a utilizar con este tipo.
7 Conjuntos	25min	Descripción del tipo de datos conjunto y los comandos a utilizar con este tipo.
8 Servicio de mensajería	20min	Descripción del concepto de mensajería, junto a los comandos a utilizar para trabajar con el implementado en Redis.
9 Arrays asociativos	15min	Descripción del tipo de datos array asociativo y los comandos a utilizar con este tipo.
10 JSON	15min	Descripción del tipo de datos JSON y los comandos a utilizar con este tipo proporcionados por el módulo ReJSON.
11 Introducción a Lua	50min	Introducción al lenguaje de programación Lua, utilizado por Redis para la realización de consultas complejas en el servidor.
12 Scripts Lua en Redis	20min	Cómo ejecutar *scripts* Lua en Redis.
13 Bibliotecas de Lua	20min	Descripción de varias bibliotecas de Lua útiles, integradas en el intérprete de Redis.
14 Depuración de scripts Lua en Redis	25min	Descripción del concepto de depuración y del depurador proporcionado por Redis para Lua.
15 Introducción a las transacciones	30min	Descripción detallada del concepto de transacción.
16 Transacciones en Redis	15min	Cómo implementa Redis las transacciones.
17 Cursores	20min	Descripción del concepto de cursor y su implementación en Redis.
a1 Módulos en Lua	15min	Descripción del concepto de módulo en Lua, como medio para la reutilización de software.
a2 POO en Lua	35min	Descripción de la programación orientada a objetos en Lua.

Información de publicación

Título Aprende bases de datos NoSQL con Redis

Autor Raúl G. González - raulggonzalez@nodemy.com

Primera edición Abril de 2017
Versión actual 1.0.0
Versión de Redis 4.0
Contacto hola@nodemy.com

